

Maestría en Sistemas Embebidos

Programación y Procesamiento de Datos

3A. Práctica de manejo de datos en Python



Alumno: Claudio Iván Esparza Castañeda
Profesor: Luis Alberto Balam Guzmán

Objetivo

Más allá de las funciones incluidas en el estándar de Python, la amplia comunidad comenzó a implementar funciones más complejas que agrupan múltiples funciones orientadas a tópicos específicos. La idea es que no se tenga que reinventar la rueda cada vez. Con este espíritu es que se crearon módulos (propriadamente el equivalente de las bibliotecas o librería de otros lenguajes) como pandas, el cual tiene funciones para manipular los arreglos mixtos como dataframe, yendo más allá de los datos numéricos, permite interpretar otras utilidades como el tipo fecha, o las múltiples combinaciones propias del tipo texto. Otra de gran utilidad es Matplotlib, que contiene múltiples representaciones gráficas para los datos obtenidos con otros módulos.

La popularidad de Pandas en combinación de Matplotlib de manera reciente viene de su uso en análisis de datos, de la inteligencia artificial, entre otros campos. Las aplicaciones, claro, son infinitas y corresponde a uno plantearse la manera en que quisiera realizar estas tareas.

Se retoma el reciclaje de funciones, sin ninguna adición.

Combinando los conocimientos usados en las prácticas anteriores, se combina para tener clases, listas iterables, y ahora el uso de pandas y Matplotlib para tener dataframes y su representación gráfica. Este programa involucra el uso de un menú para el control del flujo. Se cuenta con validaciones para los distintos tipos de datos que se emplean en el programa, y se cuenta con una Clase "Clima" con métodos para cada etapa opción del menú.

Capturas de ejecución

```
===== MENÚ PRINCIPAL =====
1. Cargar datos
2. Exploración inicial
3. Indexamiento
4. Filtrado y agrupamiento
5. Series de tiempo
6. Gráficas
7. Salir
Selecciona una opción: 1

--- Cargar datos ---
No se encontró el archivo 'clima_2023.csv'.
```

Figure 1: Validación de archivo de entrada no encontrado.

```
===== MENÚ PRINCIPAL =====
1. Cargar datos
2. Exploración inicial
3. Indexamiento
4. Filtrado y agrupamiento
5. Series de tiempo
6. Gráficas
7. Salir
Selecciona una opción: 2

--- Exploración inicial ---
Primero debes cargar los datos (opción 1).
```

Figure 2: Opción 2 no realizada por falta de datos cargados.

```
===== MENU PRINCIPAL =====
1. Cargar datos
2. Exploración inicial
3. Indexamiento
4. Filtrado y agrupamiento
5. Series de tiempo
6. Gráficas
7. Salir
Selecciona una opción: 3

--- Indexamiento ---
Primero debes cargar los datos (opción 1).
```

Figure 3: Opción 3 no realizada por falta de datos cargados.

```
===== MENU PRINCIPAL =====
1. Cargar datos
2. Exploración inicial
3. Indexamiento
4. Filtrado y agrupamiento
5. Series de tiempo
6. Gráficas
7. Salir
Selecciona una opción: 4

--- Filtrado y agrupamiento ---
Primero debes cargar los datos (opción 1).
```

Figure 4: Opción 4 no realizada por falta de datos cargados.

```
===== MENU PRINCIPAL =====
1. Cargar datos
2. Exploración inicial
3. Indexamiento
4. Filtrado y agrupamiento
5. Series de tiempo
6. Gráficas
7. Salir
Selecciona una opción: 5

--- Series de tiempo ---
Primero debes cargar los datos (opción 1).
```

Figure 5: Opción 5 no realizada por falta de datos cargados.

```
===== MENU PRINCIPAL =====
1. Cargar datos
2. Exploración inicial
3. Indexamiento
4. Filtrado y agrupamiento
5. Series de tiempo
6. Gráficas
7. Salir
Selecciona una opción: 6

--- Gráficas ---
Primero debes cargar los datos (opción 1).
```

Figure 6: Opción 6 no realizada por falta de datos cargados.

```
===== MENÚ PRINCIPAL =====
1. Cargar datos
2. Exploración inicial
3. Indexamiento
4. Filtrado y agrupamiento
5. Series de tiempo
6. Gráficas
7. Salir
Selecciona una opción: 7
Finalizando el programa...
```

Figure 7: Salida correcta del programa

```
===== MENU PRINCIPAL =====
1. Cargar datos
2. Exploración inicial
3. Indexamiento
4. Filtrado y agrupamiento
5. Series de tiempo
6. Gráficas
7. Salir
Selecciona una opción: 1

--- Cargar datos ---
Datos cargados correctamente: 365 registros.
```

Figure 8: Carga correcta de datos.

```

Selecciona una opción: 2

--- Exploración inicial ---
Primeras 10 filas:
  fecha  temperatura  humedad  precipitacion  mes
0 2023-01-01      22.8      77.7           1      1
1 2023-01-02      20.1      33.7           0      1
2 2023-01-03      17.2      50.4           5      1
3 2023-01-04      19.6      75.0           0      1
4 2023-01-05      21.9      58.5           0      1
5 2023-01-06      16.1      47.5          10      1
6 2023-01-07      26.3      69.6           0      1
7 2023-01-08      21.1      77.2           1      1
8 2023-01-09      15.2      29.1           2      1
9 2023-01-10      24.5      25.0           0      1

Información general:
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 365 entries, 0 to 364
Data columns (total 5 columns):
#   Column          Non-Null Count  Dtype
---  ---
0   fecha            365 non-null   datetime64[ns]
1   temperatura      365 non-null   float64
2   humedad          365 non-null   float64
3   precipitacion    365 non-null   int64
4   mes              365 non-null   int32
dtypes: datetime64[ns](1), float64(2), int32(1), int64(1)
memory usage: 13.0 KB

Estadísticas descriptivas:
  fecha  temperatura  humedad  precipitacion  mes
count      365      365.000000  365.000000  365.000000  365.000000
mean  2023-07-02 00:00:00  26.633973  53.544110  2.621918  6.526027
min    2023-01-01 00:00:00  15.000000  25.000000  0.000000  1.000000
25%    2023-04-02 00:00:00  22.300000  39.200000  0.000000  4.000000
50%    2023-07-02 00:00:00  26.600000  54.900000  1.000000  7.000000
75%    2023-10-01 00:00:00  30.400000  67.800000  5.000000  10.000000
max    2023-12-31 00:00:00  39.800000  79.800000  10.000000  12.000000
std                NaN      5.601535  16.472982  3.509729  3.452584

```

Figure 9: Exploración inicial.

```

Selecciona una opción: 3

--- Indexamiento ---
Columna de temperatura:
0      22.8
1      20.1
2      17.2
3      19.6
4      21.9
...
360    27.2
361    20.2
362    24.3
363    21.3
364    21.9
Name: temperatura, Length: 365, dtype: float64

Filas del día 50 al 70:
  fecha  temperatura  humedad  precipitacion  mes
49 2023-02-19      15.7      56.8           0      2
50 2023-02-20      17.4      27.1           5      2
51 2023-02-21      16.5      65.8           0      2
52 2023-02-22      25.6      37.7           5      2
53 2023-02-23      24.0      49.9           5      2
54 2023-02-24      22.8      66.4           2      2
55 2023-02-25      20.5      79.2           2      2
56 2023-02-26      19.8      34.4          10      2
57 2023-02-27      19.0      68.0           0      2
58 2023-02-28      19.8      28.9           5      2
59 2023-03-01      21.5      38.3           0      3
60 2023-03-02      32.8      41.1           2      3
61 2023-03-03      26.6      58.1           2      3
62 2023-03-04      28.3      27.7           2      3
63 2023-03-05      25.1      68.0          10      3
64 2023-03-06      24.1      76.2          10      3
65 2023-03-07      27.3      78.7           0      3
66 2023-03-08      20.6      55.5           2      3
67 2023-03-09      20.1      59.1           0      3
68 2023-03-10      20.4      58.0           2      3
69 2023-03-11      28.5      40.9           0      3

```

Figure 10: Indexamiento.

```

Selecciona una opción: 4

--- Filtrado y agrupamiento ---
Días con temperatura mayor a 30° (100 registros):
  fecha      temperatura  humedad  precipitacion  mes
60  2023-03-02         32.8    41.1           2         3
71  2023-03-13         32.0    57.5           0         3
73  2023-03-15         34.8    40.0           5         3
75  2023-03-17         30.9    25.8           2         3
76  2023-03-18         30.5    64.0           0         3
..      ...           ...      ...         ...      ...
289 2023-10-17         31.6    64.2           5        10
308 2023-11-05         31.2    30.1           0        11
310 2023-11-07         30.1    37.0           1        11
330 2023-11-27         30.3    76.3           1        11
332 2023-11-29         30.5    32.7           1        11

[100 rows x 5 columns]

Días con humedad menor a 40% (95 registros):
  fecha      temperatura  humedad  precipitacion  mes
1  2023-01-02         20.1    33.7           0         1
8  2023-01-09         15.2    29.1           2         1
9  2023-01-10         24.5    25.0           0         1
13 2023-01-14         19.9    39.9           0         1
15 2023-01-16         17.9    31.4           2         1
..      ...           ...      ...         ...      ...
351 2023-12-18         22.0    32.9           5        12
352 2023-12-19         20.0    29.3           0        12
353 2023-12-20         22.9    38.3           0        12
356 2023-12-23         21.1    33.4           2        12
364 2023-12-31         21.9    29.9           0        12

[95 rows x 5 columns]

DataFrame ordenado por temperatura (mayor a menor):
  fecha      temperatura  humedad  precipitacion  mes
218 2023-08-07         39.8    33.8           0         8
190 2023-07-10         39.6    48.2           0         7
168 2023-06-18         39.5    63.4          10         6

```

Figure 11: Filtrado y agrupamiento.

```

Selecciona una opción: 5

--- Series de tiempo ---
Registros de junio de 2023:
  fecha      temperatura  humedad  precipitacion  mes
2023-06-01         37.3    52.6           0         6
2023-06-02         28.1    34.4          10         6
2023-06-03         36.6    52.7           5         6
2023-06-04         29.0    32.7           0         6
2023-06-05         33.9    25.0           2         6
2023-06-06         25.6    34.4           1         6
2023-06-07         35.2    54.4          10         6
2023-06-08         37.9    79.8           0         6
2023-06-09         35.1    79.5           5         6
2023-06-10         35.3    44.7           1         6
2023-06-11         32.0    37.8          10         6
2023-06-12         31.2    78.9           2         6
2023-06-13         39.5    49.1           5         6
2023-06-14         39.4    27.4           0         6
2023-06-15         32.3    78.9           2         6
2023-06-16         29.2    71.8          10         6
2023-06-17         25.1    47.1           2         6
2023-06-18         39.5    63.4          10         6
2023-06-19         30.5    78.8           5         6
2023-06-20         29.5    44.5          10         6
2023-06-21         27.8    58.7           5         6
2023-06-22         25.1    25.9          10         6
2023-06-23         30.9    77.1           5         6
2023-06-24         37.2    48.9           0         6
2023-06-25         36.2    53.6           0         6
2023-06-26         29.1    52.4           0         6
2023-06-27         30.7    72.5           1         6
2023-06-28         32.7    39.2           1         6
2023-06-29         26.3    74.5           0         6
2023-06-30         25.1    60.8           2         6

Primer trimestre del año (enero-marzo 2023):

```

Figure 12: Series de tiempo.




Figure 13: Gráficas.

Pseudocódigo

Ya desde prácticas anteriores PSeInt estaba rebasado para plasmar estos algoritmos más complejos, aquí traté de expresarlo en lenguaje natural. Por la simpleza de python, mucho fue traducir de inglés a español.

Inicialización

Listing 1: Inicialización

```

1  CONSTANTE ARCHIVO_CSV <- "clima_2023.csv"
2  CONSTANTE COLUMNAS_REQUERIDAS <- {"fecha", "temperatura", "humedad", "
   precipitation"}
3  PROCEDIMIENTO Menu()
4      IMPRIMIR "===== MENÚ PRINCIPAL ====="
5      IMPRIMIR "1. Cargar datos"
6      IMPRIMIR "2. Exploración inicial"
7      IMPRIMIR "3. Indexamiento"
8      IMPRIMIR "4. Filtrado y agrupamiento"
9      IMPRIMIR "5. Series de tiempo"
10     IMPRIMIR "6. Gráficas"
11     IMPRIMIR "7. Salir"
12  FIN PROCEDIMIENTO

```

Clase Clima

Listing 2: Clase Clima

```

1  CLASE ClimaPandas
2      ATRIBUTOS
3          df : DataFrame
4      CONSTRUCTOR ClimaPandas()
5          df <- NULO
6      FIN CONSTRUCTOR
7      FUNCIÓN HayDatos(): Booleano
8          SI df = NULO ENTONCES
9              IMPRIMIR "Primero debes cargar los datos (opción 1)."
10             RETORNAR FALSO
11         FIN SI
12         RETORNAR VERDADERO
13     FIN FUNCIÓN
14     PROCEDIMIENTO AsegurarIndiceFecha()
15         SI el índice de df NO es de tipo fecha ENTONCES
16             df <- EstablecerIndice(df, "fecha")

```

```

17         df <- OrdenarPorIndice(df)
18     FIN SI
19 FIN PROCEDIMIENTO
20 PROCEDIMIENTO CargarDatos()
21     IMPRIMIR "---- Cargar datos ----"
22     INTENTAR
23         datos <- LeerCSV(ARCHIVO_CSV)
24     CAPTURAR ArchivoNoEncontrado
25         IMPRIMIR "No se encontró el archivo '", ARCHIVO_CSV, "'. "
26     RETORNAR
27     CAPTURAR ArchivoVacio
28         IMPRIMIR "El archivo '", ARCHIVO_CSV, "' está vacío."
29     RETORNAR
30 FIN INTENTAR
31 SI NO ColumnasRequeridasPresentes(datos, COLUMNAS_REQUERIDAS) ENTONCES
32     IMPRIMIR "El archivo no tiene las columnas esperadas: ",
33         COLUMNAS_REQUERIDAS
34     IMPRIMIR "Columnas encontradas: ", ColumnasDe(datos)
35     RETORNAR
36 FIN SI
37 datos["fecha"] <- ConvertirADatetime(datos["fecha"])
38 datos["mes"] <- ExtraerMes(datos["fecha"])
39 df <- datos
40 IMPRIMIR "Datos cargados correctamente: ", CantidadFilas(df), " registros
41 . "
42 FIN PROCEDIMIENTO
43 PROCEDIMIENTO Exploracion()
44     IMPRIMIR "---- Exploración inicial ----"
45     SI NO HayDatos() ENTONCES
46         RETORNAR
47     FIN SI
48     IMPRIMIR "Primeras 10 filas:"
49     IMPRIMIR PrimerasFilas(df, 10)
50     IMPRIMIR "Información general:"
51     IMPRIMIR InformacionGeneral(df)
52     IMPRIMIR "Estadísticas descriptivas:"
53     IMPRIMIR EstadisticasDescriptivas(df) // media, min, max, cuartiles, etc.
54 FIN PROCEDIMIENTO
55 PROCEDIMIENTO Indexamiento()
56     IMPRIMIR "---- Indexamiento ----"
57     SI NO HayDatos() ENTONCES
58         RETORNAR
59     FIN SI
60     IMPRIMIR "Columna de temperatura:"
61     IMPRIMIR df["temperatura"]
62     IMPRIMIR "Filas del día 50 al 70:"
63     IMPRIMIR FilasPorPosicion(df, DESDE 49 HASTA 69) // día n = posición n
64     -1
65     IMPRIMIR "Temperatura y humedad de los primeros 100 registros:"
66     IMPRIMIR PrimerasFilas(df[["temperatura", "humedad"]], 100)
67     IMPRIMIR "Temperatura del día 120: ", FilaPorPosicion(df, 119)["
68     temperatura"]
69     IMPRIMIR "Humedad del día 200: ", FilaPorPosicion(df, 199)["humedad"]
70 FIN PROCEDIMIENTO
71 PROCEDIMIENTO FiltradoAgrupamiento()
72     IMPRIMIR "---- Filtrado y agrupamiento ----"
73     SI NO HayDatos() ENTONCES
74         RETORNAR
75     FIN SI
76     calidos <- Filtrar(df, temperatura > 30)

```

```

73     IMPRIMIR "Días con temperatura mayor a 30 (" , CantidadFilas(calidos), "
      registros):"
74     IMPRIMIR calidos
75     secos <- Filtrar(df, humedad < 40)
76     IMPRIMIR "Días con humedad menor a 40% (" , CantidadFilas(secos), "
      registros):"
77     IMPRIMIR secos
78     ordenado <- OrdenarPor(df, "temperatura", DESCENDENTE)
79     IMPRIMIR "DataFrame ordenado por temperatura (mayor a menor):"
80     IMPRIMIR ordenado
81     agrupado <- AgruparPor(df, "mes") CON
82     temperatura_promedio <- Media(temperatura)
83     humedad_promedio <- Media(humedad)
84     precipitacion_total <- Suma(precipitacion)
85     IMPRIMIR "Agrupamiento por mes:"
86     IMPRIMIR agrupado
87 FIN PROCEDIMIENTO
88 PROCEDIMIENTO SeriesTiempo()
89     IMPRIMIR "--- Series de tiempo ---"
90     SI NO HayDatos() ENTONCES
91         RETORNAR
92     FIN SI
93     AsegurarIndiceFecha()
94     IMPRIMIR "Registros de junio de 2023:"
95     IMPRIMIR df[fecha PERTENECE A "2023-06"]
96     IMPRIMIR "Primer trimestre del año (enero-marzo 2023):"
97     IMPRIMIR df[fecha ENTRE "2023-01" Y "2023-03"]
98     promedio_semanal <- PromedioPorSemana(df["temperatura"]) // resample
      semanal
99     IMPRIMIR "Promedio semanal de temperatura:"
100    IMPRIMIR promedio_semanal
101 FIN PROCEDIMIENTO
102 PROCEDIMIENTO Graficas()
103     IMPRIMIR "--- Gráficas ---"
104     SI NO HayDatos() ENTONCES
105         RETORNAR
106     FIN SI
107     AsegurarIndiceFecha()
108     CREAR figura CON 1 fila Y 3 columnas DE subgráficas: panel_linea,
      panel_barras, panel_hist
109     TituloGeneral(figura, "Análisis de Datos Climáticos - 2023")
110     DibujarLinea(panel_linea, eje_x <- df.indice, eje_y <- df["temperatura"],
      color <- ROJO)
111     Titulo(panel_linea, "Temperatura diaria")
112     EtiquetaEjeX(panel_linea, "Fecha")
113     EtiquetaEjeY(panel_linea, "Temperatura (C)")
114     RotarEtiquetasEjeX(panel_linea, 45)
115     precipitacion_mensual <- AgruparPor(df, "mes") Y Sumar(precipitacion)
116     DibujarBarras(panel_barras, eje_x <- precipitacion_mensual.meses,
      eje_y <- precipitacion_mensual.valores, color <- AZUL)
117     Titulo(panel_barras, "Precipitación total por mes")
118     EtiquetaEjeX(panel_barras, "Mes")
119     EtiquetaEjeY(panel_barras, "Precipitación (mm)")
120     DibujarHistograma(panel_hist, datos <- df["temperatura"], num_barras <-
      20, color <- VERDE)
121     Titulo(panel_hist, "Distribución de temperaturas")
122     EtiquetaEjeX(panel_hist, "Temperatura (C)")
123     EtiquetaEjeY(panel_hist, "Frecuencia")
124     MostrarFigura(figura)
125
126 FIN PROCEDIMIENTO

```


Algoritmo principal

Listing 3: Algoritmo principal

```
1  ALGORITMO Principal
2  opcion <- 0
3  clima <- NUEVO ClimaPandas()
4  Menu()
5  MIENTRAS opcion <> 7 HACER
6      opcion <- PedirEntero("Selecciona una opción: ")
7      SI opcion = 1 ENTONCES
8          clima.CargarDatos()
9      SINO SI opcion = 2 ENTONCES
10         clima.Exploracion()
11     SINO SI opcion = 3 ENTONCES
12         clima.Indexamiento()
13     SINO SI opcion = 4 ENTONCES
14         clima.FiltradoAgrupamiento()
15     SINO SI opcion = 5 ENTONCES
16         clima.SeriesTiempo()
17     SINO SI opcion = 6 ENTONCES
18         clima.Graficas()
19     SINO SI opcion <> 7 ENTONCES
20         IMPRIMIR "Opción no válida"
21     FIN SI
22     SI opcion <> 7 ENTONCES
23         Menu()
24     FIN SI
25 FIN MIENTRAS
26 IMPRIMIR "Finalizando el programa..."
27 FIN ALGORITMO
```

Conclusiones

La reusabilidad de funciones usadas en tareas anteriores contribuye a tener código reusable en todos los niveles.

Junto con NumPy, pandas y Matplotlib se han ganado un lugar entre los módulos más usados para tareas que manejan muchísimos datos en Python. Sus aplicaciones abarcan múltiples campos. La carpeta en el repositorio de este proyecto es: Programación y procesamiento de Datos.